# **Projet 3**



Adrian Rodriguez - Ingénieur Machine Learning



**DPENCLASSROOMS** 





### Emissions carbone et consommation d'énergie




### Présentation du jeu de données

- 3340 observations
  - 47 variables





- 3376 observations
- 46 variables




- Traitement des bâtiments en double
- Exclusion des bâtiments résidentiels



- 1727 observations
- 46 variables



### **Consistance des données**



Surface GFA



Tower




Energy use






### Feature engineering - Localisation

Site Energy Use (kBtu)



GHG Emissions (TonsCO2)






# Features engineering - Usage/Equipement





## Features engineering - Bâtiment

Ratio des surfaces



Hauteur des bâtiments



Période de construction






Score > 75 = Top performer



# **Exploration des variables quantitatives**





- Distributions non gaussienne
- Variances élevées




### Choix des modèles

Méthodes linéaires	Arbre de décision	Méthode ensembliste
- Ridge - Lasso	- DecisionTreeRegressor	<ul><li>RandomForestRegressor</li><li>GradientBoostingRegressor</li></ul>
<u>Hyperparamètres :</u> - alpha	<u>Hyperparamètres :</u> - max_depth - min_samples_split	Hyperparamètres : - max_depth - min_samples_split - n_estimators



#### **Features selection**





#### Modélisation

Choix du modèle Analyse des résultats sur données de test Réglage des plages des hyperparamètres Récupération des RMSE et r2 Processus de modélisation

Ajustement du modèle sur données d'entraînement

Cross-Validation 5 fois / Métrique RMSE / Récupération des meilleurs hyperparamètres



### Validation des modèles

#### Consommation d'énergie

EnergyUse	Test : RMSE	Test : R2	mean_test_score	std_test_score	alpha	max_depth	min_samples_split	n_estimators
Ridge	-0.4367	0.8084	-0.4831	0.0479	7.5753	nan	nan	nan
Lasso	-0.4363	0.8088	-0.4813	0.0485	0.0116	nan	nan	nan
Decision-Tree	-0.4972	0.7516	-0.5292	0.0477	nan	8.0	20.0	nan
RandomForest	-0.4326	0.812	-0.4908	0.0483	nan	8.0	12.0	1000.0
GradientBoosting	-0.44	0.8055	-0.4788	0.0424	nan	4.0	500.0	100.0

#### **Emissions** carbone

GHGE	Test : RMSE	Test : R2	mean_test_score	std_test_score	alpha	max_depth	min_samples_split	n_estimators
Ridge	-0.6403	0.5806	-0.6687	0.0465	10.7189	nan	nan	nan
Lasso	-0.6386	0.5827	-0.6687	0.046	0.0041	nan	nan	nan
Decision-Tree	-0.655	0.561	-0.7347	0.0564	nan	6.0	50.0	nan
RandomForest	-0.6348	0.5876	-0.6796	0.0503	nan	8.0	20.0	100.0
GradientBoosting	-0.6371	0.5846	-0.6677	0.0447	nan	4.0	200.0	50.0





### Rôle de l'Energy Star Score

#### Émissions carbone avec Energy Star Score

GHGE	Test : RMSE	Test : R2	mean_test_score	std_test_score	alpha	max_depth	min_samples_split	n_estimators
Ridge	-0.6403	0.5806	-0.6687	0.0465	10.7189	nan	nan	nan
Lasso	-0.6386	0.5827	-0.6687	0.046	0.0041	nan	nan	nan
Decision-Tree	-0.655	0.561	-0.7347	0.0564	nan	6.0	50.0	nan
RandomForest	-0.6348	0.5876	-0.6796	0.0503	nan	8.0	20.0	100.0
GradientBoosting	-0.6371	0.5846	-0.6677	0.0447	nan	4.0	200.0	50.0

#### Émissions carbone sans Energy Star Score

GHGE_sans_ESS	Test : RMSE	Test : R2	mean_test_score	std_test_score	alpha	max_depth	min_samples_split	n_estimators
Ridge	-0.6946	0.5064	-0.7123	0.049	9.5477	nan	nan	nan
Lasso	-0.6935	0.5079	-0.7114	0.0493	0.0065	nan	nan	nan
Decision-Tree	-0.6954	0.5052	-0.7449	0.0659	nan	6.0	50.0	nan
RandomForest	-0.6801	0.5268	-0.7072	0.0542	nan	6.0	20.0	50.0
GradientBoosting	-0.6854	0.5194	-0.702	0.0437	nan	4.0	200.0	50.0



### Modèle final

	Consommation d'énergie	Emissions carbone
Modèle	Random Forest	Random Forest
RMSE	0.44	0.63
r2	0.81	0.58



